МИНОБРНАУКИ РОССИИ
САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ
ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)
Кафедра МО ЭВМ

ИНДИВИДУАЛЬНОЕ ДОМАШНЕЕ ЗАДАНИЕ

по дисциплине «Введение в нереляционные базы данных»

Тема: БД вакансий

Студентка гр. 8383 Ишанина Л.Н.

Студент гр. 8383 Ларин А.

Студентка гр. 8383 Сырцова Е.А.

Преподаватель Заславский М.М.

Санкт-Петербург

2021

ЗАДАНИЕ

НА ИНДИВИДУАЛЬНОЕ ДОМАШНЕЕ ЗАДАНИЕ

Студенты Ишанина Л.Н., Ларин А., Сырцова Е.А.

Группа 8383

Тема проекта: БД вакансий

Исходные данные:

Веб-инструмент для CRUD вакансий, а также продвинутой аналитики (включая графовое представление).

Содержание пояснительной записки:

«Содержание», «Введение», «Качественные требования», «Сценарий использования», «Модель данных», «Разработанное приложение», «Заключение»

Предполагаемый объем пояснительной записки:

Не менее 10 страниц.

Дата выдачи задания: 13.09.2021

Дата сдачи реферата: 28.12.2021

Дата защиты реферата: 28.12.2021

Студентка гр. 8383		Ишанина Л.Н.
Студент гр. 8383		Ларин А.
Студентка гр. 8383		Сырцова Е.А.
Преподаватель		Заславский М.М.

АННОТАЦИЯ

В рамках данного курса предполагалось разработать какое-либо приложение в команде на одну из поставленных тем. Была выбрана тема создания БД вакансий hh.ru для СУБД Neo4j. Во внимание будут приниматься такие аспекты как производительность и удобство разработки. Найти исходный код и всю дополнительную информацию можно по ссылке: https://github.com/moevm/nosql2h21-jobs

SUMMARY

As part of this course, it was supposed to develop an application in a team on one of the set topics. The topic of creating a database of vacancies was chosen hh.ru for the Neo4j DBMS. Aspects such as performance and ease of development will be taken into account. You can find the source code and all additional information at the link: https://github.com/moevm/nosql2h21-jobs

СОДЕРЖАНИЕ

ВВЕДЕНИЕ

Цель работы – создать веб-инструмент для CRUD вакансий, а также продвинутой аналитики, включая графовое представление.

1. Качественные требования к решению

Требуется разработать веб-инструмент для CRUD вакансий, а также продвинутой аналитики, включая графовое представление. Приложение содержит страницу с табличным представлением списка вакансий и поиском, страницу для визуализации содержимого БД кастомной диаграммой, страницу массового импорта/экспорта всей БД, страницу графов по степени сходства вакансий. Возможная аналитика – самые востребованные/оплачиваемые/новые вакансии.

2. Сценарий использования

2.1. Макет пользовательского интерфейса

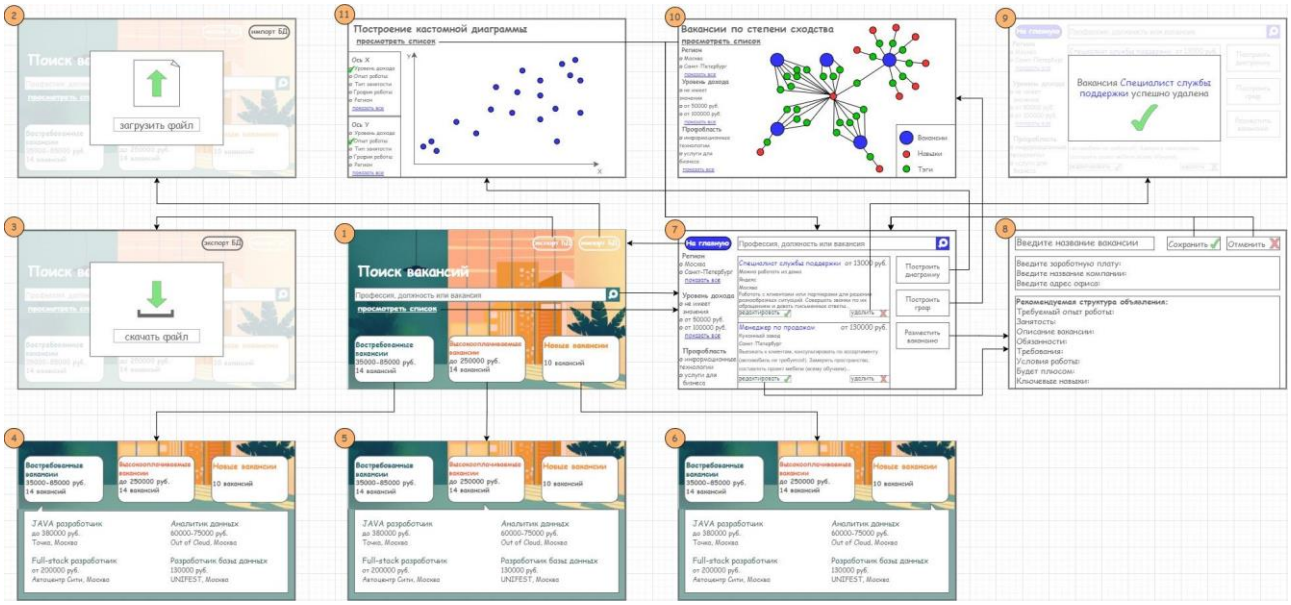

2.2. Описание сценариев использования

Единственная роль в системе - администратор. Пользователь входит на страницу (1). Он видит страницу поиска вакансий, в правом верхнем углу кнопки массового экспорта и импорта БД, внизу страницы некоторые элементы аналитики.

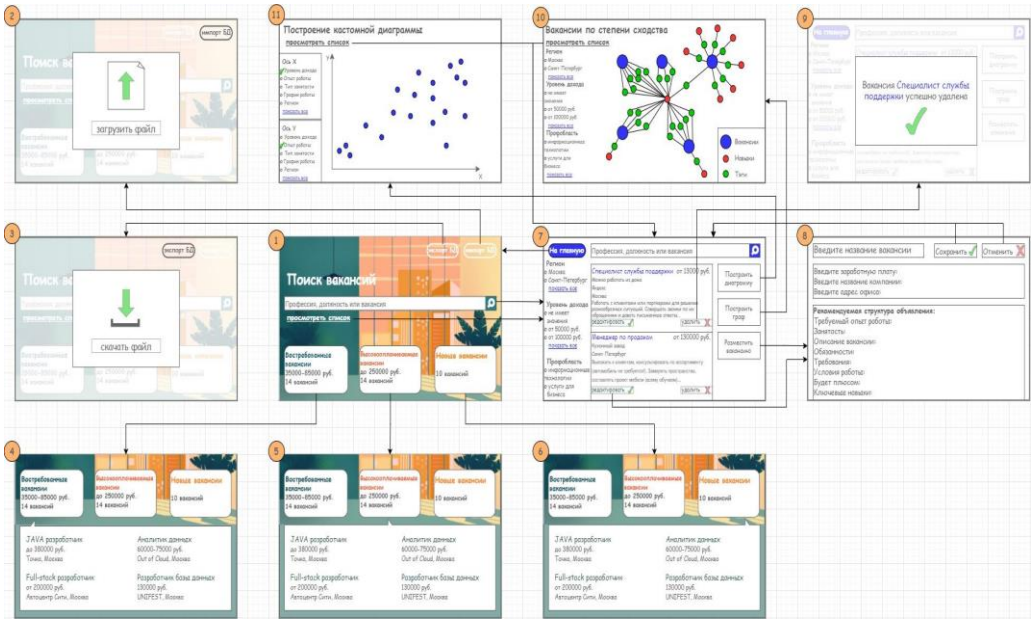

Для того чтобы **загрузить** базу данных, пользователь должен:

1. нажать на кнопку “импорт БД”
2. в открывшемся окне (2) нажать на кнопку “загрузить файл”

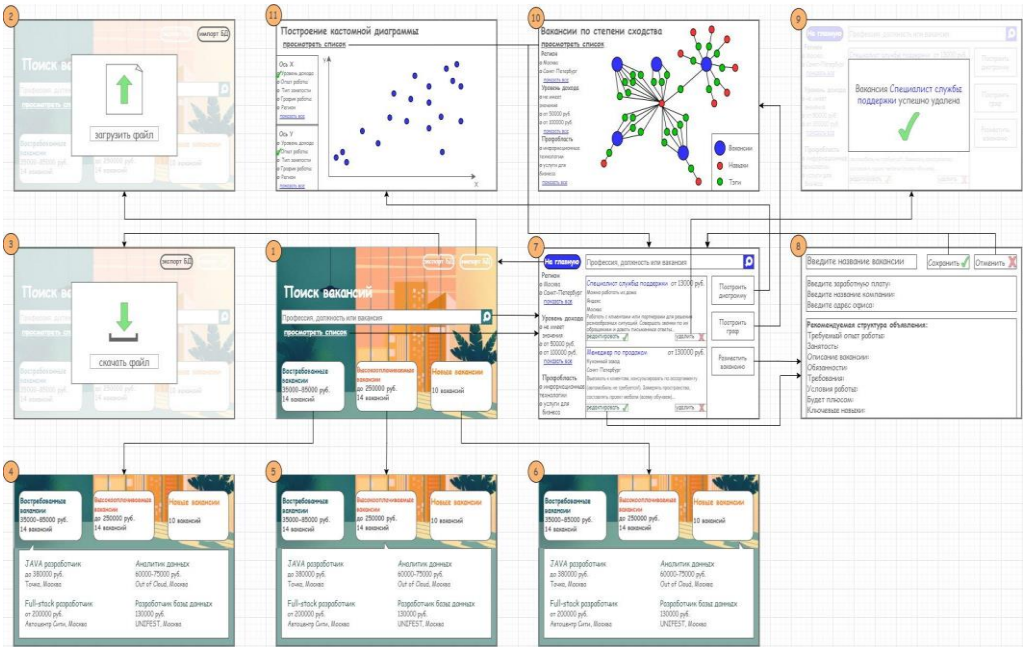

3. выбрать файл на компьютере и нажать на кнопку “загрузить”
4. подождать, пока “загрузка файла” не сменится на “база данных успешно загружена”
5. если “загрузка файла” сменилось на “ошибка загрузки базы данных”, то попробовать загрузку в другое время.

Для того чтобы **скачать** базу данных, пользователь должен:

1. нажать на кнопку “экспорт БД”
2. в открывшемся окне (3) нажать на кнопку “скачать файл”

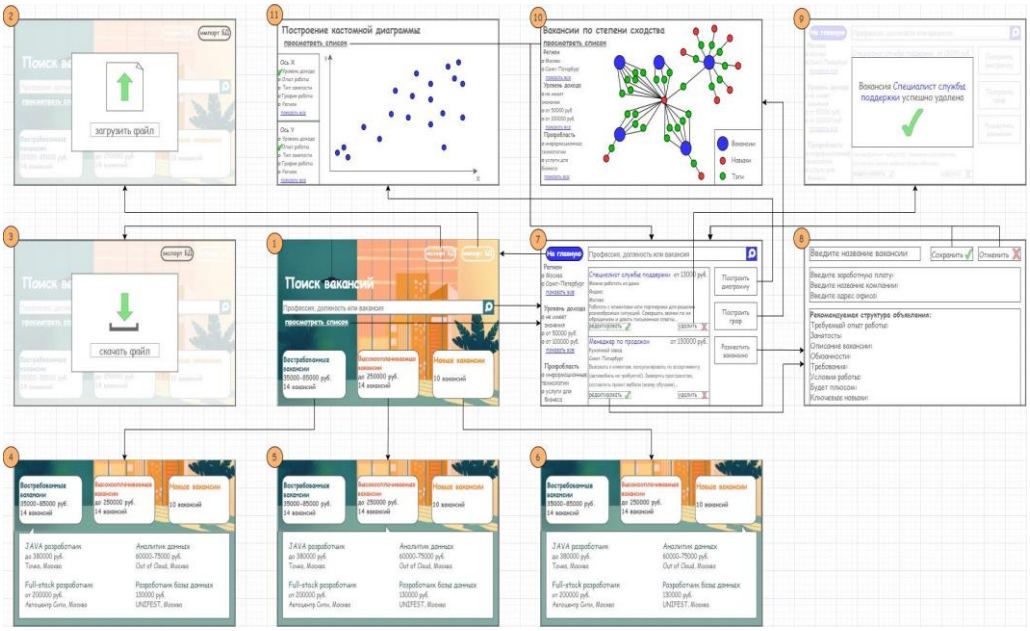

3. выбрать место скачивания на компьютере и нажать на кнопку “скачать”
4. подождать, пока “скачивание файла” не сменится на “база данных успешно скачана”
5. если “скачивание файла” сменилось на “ошибка скачивания базы данных”, то попробовать экспорт БД в другое время.

Для того чтобы **просмотреть список самых востребованных вакансий**, пользователь должен:

1. нажать на баннер “Востребованные вакансии”
2. в открывшейся таблице (4) представлен список самых востребованных вакансий

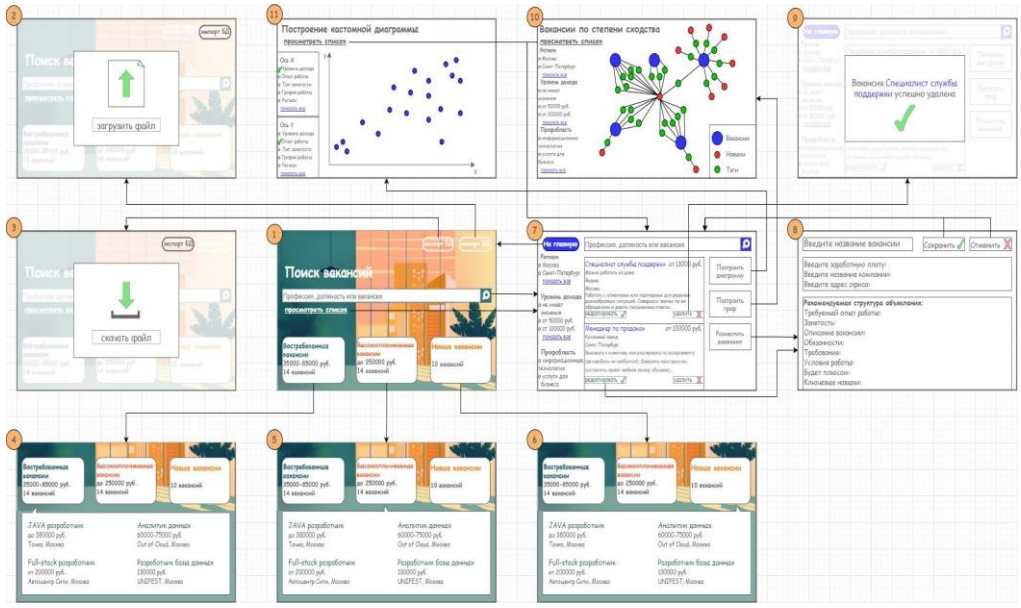

Для того чтобы **просмотреть список самых высокооплачиваемых вакансий**, пользователь должен:

1. нажать на баннер “Высокооплачиваемые вакансии”
2. в открывшейся таблице (5) представлен список самых высокооплачиваемых вакансий

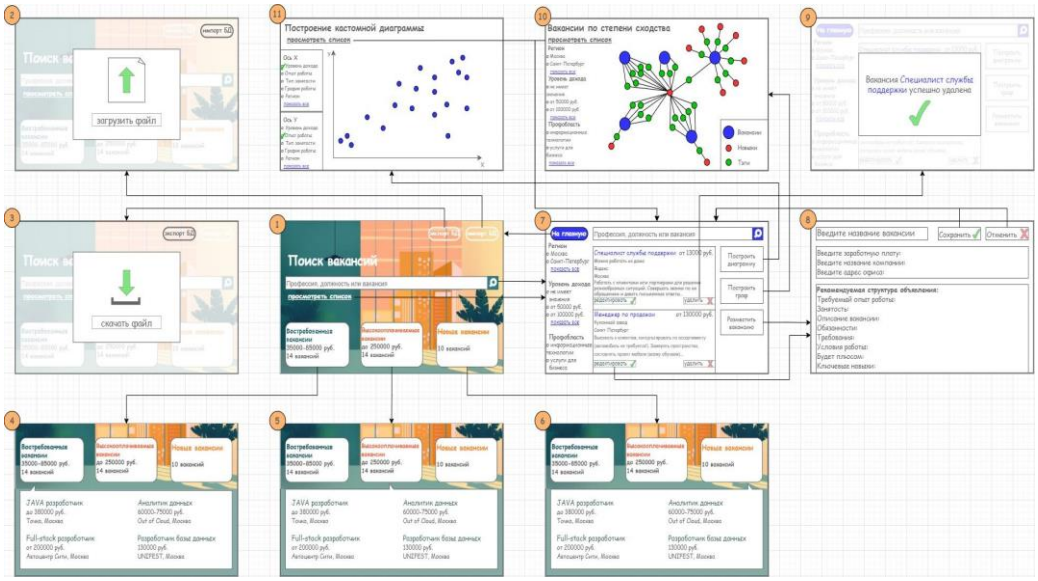

Для того чтобы **просмотреть список новых вакансий**, пользователь должен:

1. нажать на баннер “Новые вакансии”
2. в открывшейся таблице (6) представлен список самых новых вакансий

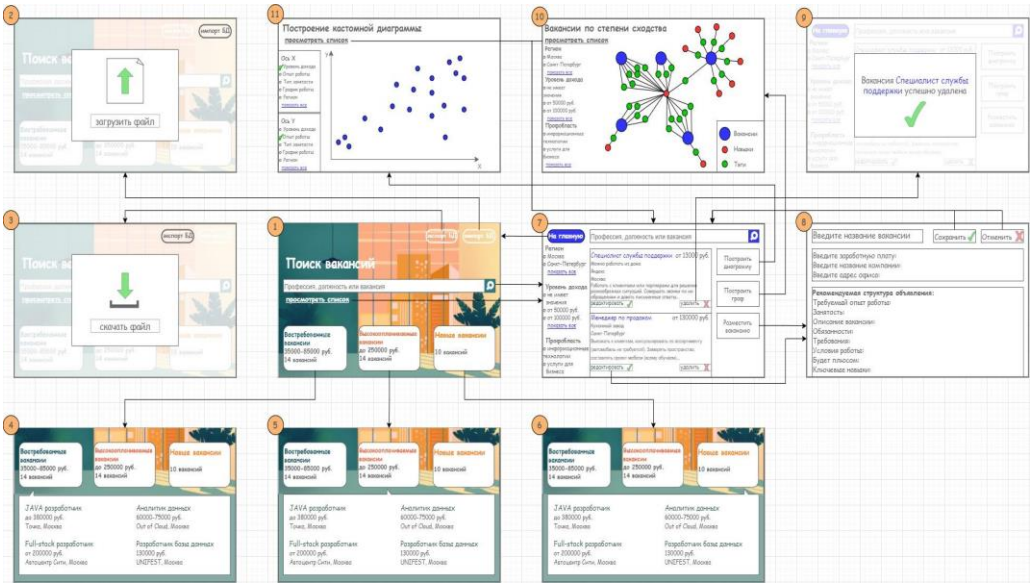

Для того чтобы **просмотреть список вакансий**, пользователь должен:

1. нажать на кнопку “просмотреть список”
2. в открывшемся окне (7) представлен список вакансий БД

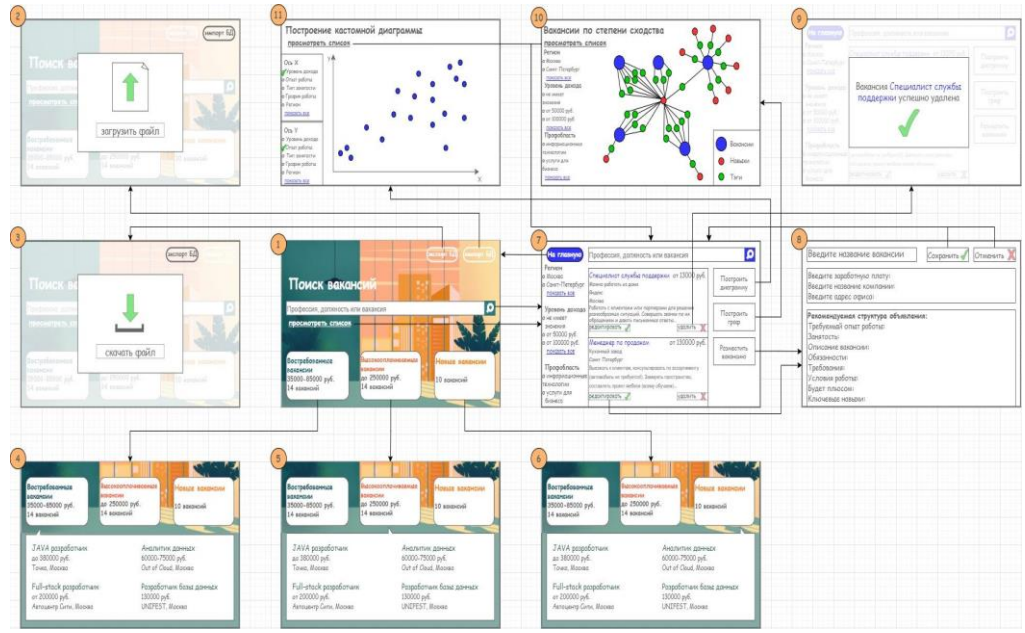

Для того чтобы осуществить **поиск вакансий**, пользователь должен:

1. ввести в строке поиска (в окне 1 или окне 7) запрос (указать профессию, должность или вакансию)
2. нажать на кнопку “лупа”
3. в открывшемся окне (7) представлен список найденных вакансий

4. дополнительно в окне 7 слева можно выбрать кластеры, список автоматически обновиться

Для того чтобы **отредактировать/разместить вакансию**, пользователь должен:

1. нажать на кнопку “редактировать” для выбранной вакансии/”Разместить вакансию”
2. в открывшемся окне (8) изменить нужные поля (Название вакансии, Заработная плата, Название компании, Адрес офиса, Требуемый опыт работы, Занятость, Описание вакансии, Обязанности, Требования, Условия работы, Будет плюсом, Ключевые навыки)

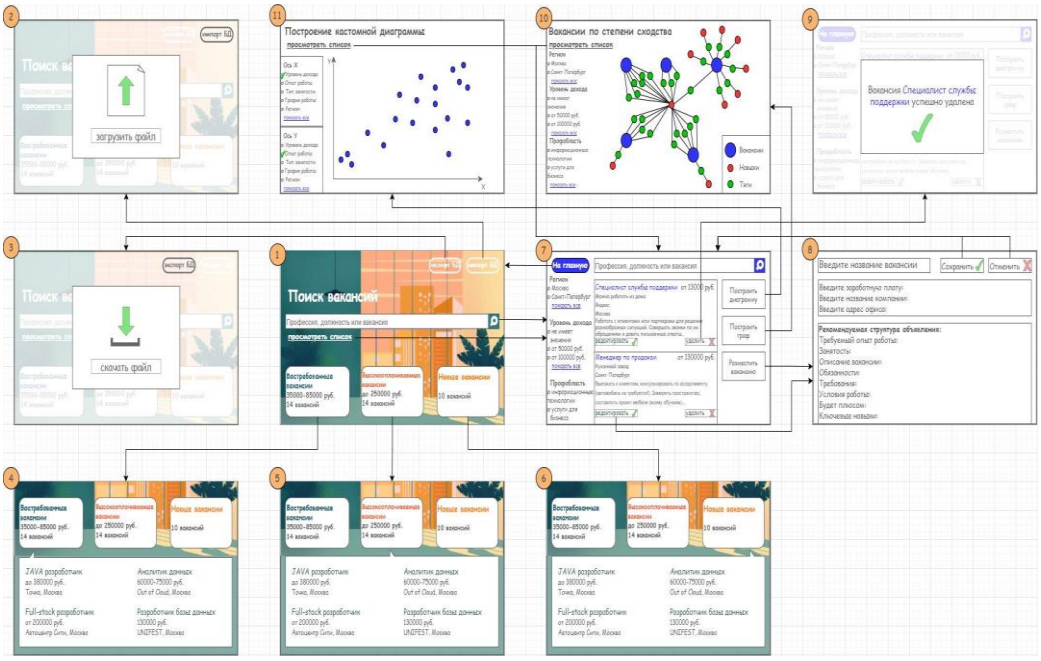

3. нажать на кнопку “Сохранить”, пользователь вернется к окну 7 с обновленным списком вакансий

Для того чтобы **удалить вакансию**, пользователь должен:

1. нажать на кнопку “удалить” для выбранной вакансии
2. в открывшемся окне 9 подождать пока “удаление вакансии” не сменится на “Вакансия успешно удалена”

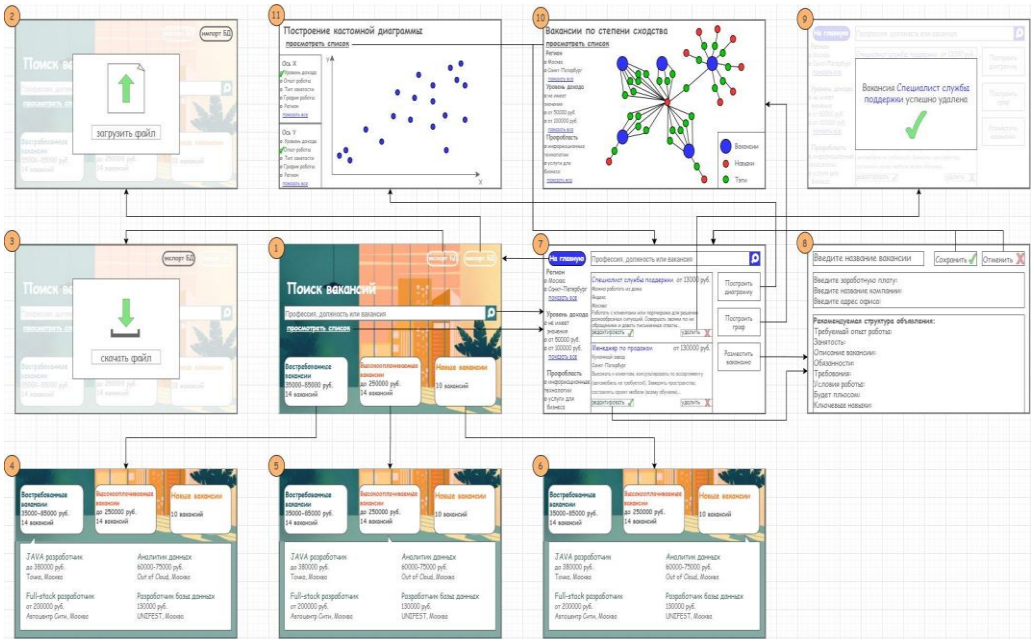

3. если “удаление вакансии” сменилось на “ошибка удаления вакансии” то попробовать удаление в другое время

Для того чтобы **построить граф вакансий по степени сходства**, пользователь должен:

1. нажать на кнопку “Построить граф” в окне 7
2. в открывшемся окне 10 можно дополнительно изменить кластеры, определяющие вакансии в построении графа

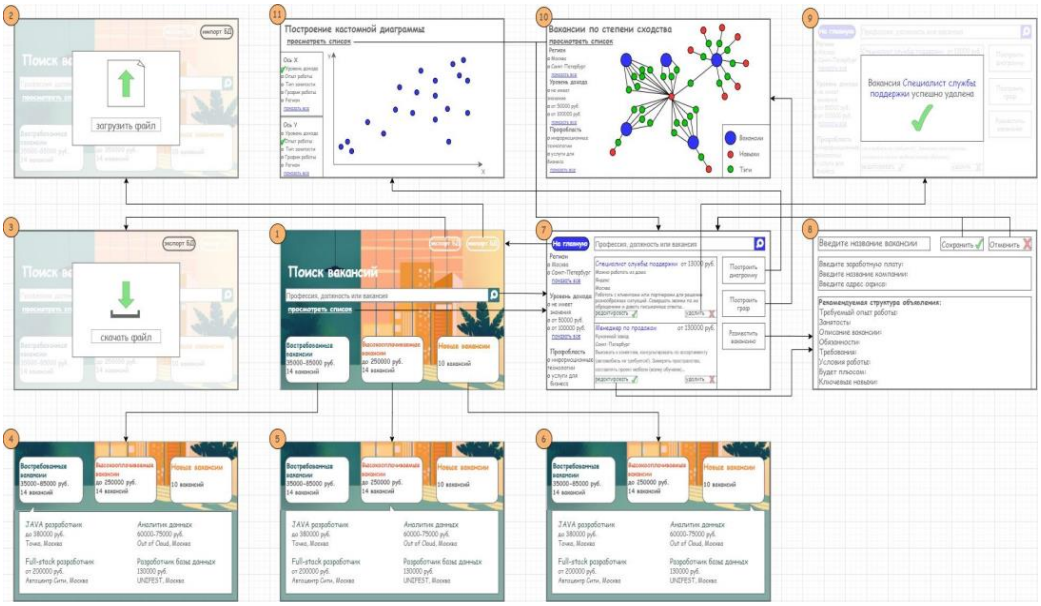

3. граф отображается автоматически

4. для того, чтобы вернуться к списку вакансий, пользователь должен нажать на кнопку “просмотреть список”

Для того чтобы **построить кастомную диаграмму**, пользователь должен:

1. нажать на кнопку “Построить диаграмму” в окне 7
2. в открывшемся окне 11 выбрать поля, задающие оси X и Y в списке слева

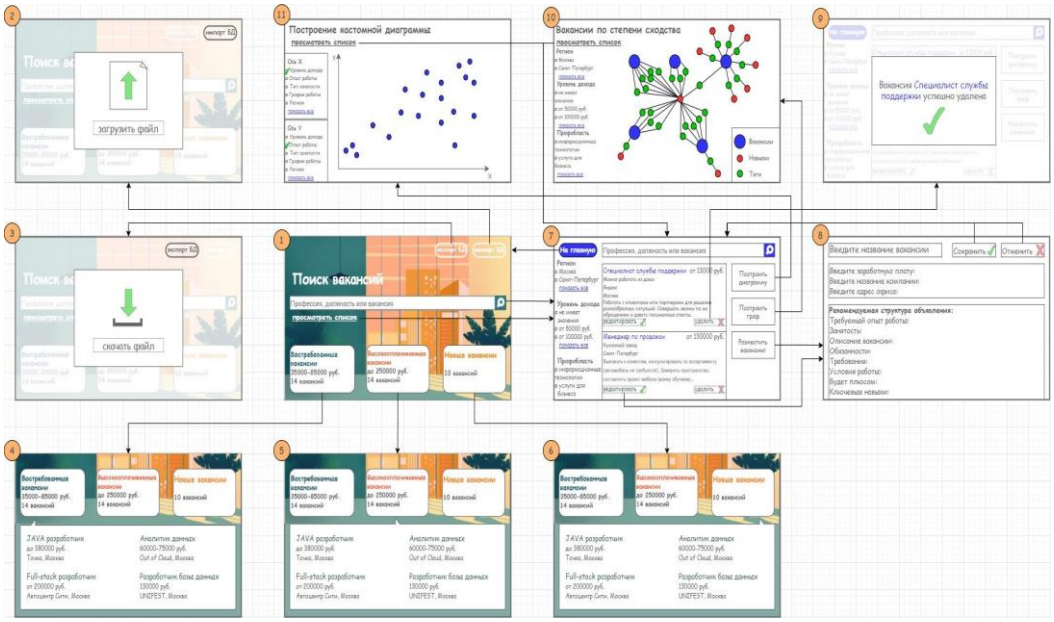

3. диаграмма отображается автоматически
4. для того, чтобы вернуться к списку вакансий, пользователь должен нажать на кнопку “просмотреть список”

3. Модель данных

3.1. Список сущностей

В терминологии neo4j данные сущности представляют из себя вершины, а их названия - метки(lable)

Area - зона, в которой располагается вакансия.

```
{
"id": "integer",
"name": "String"
}
```

Country - подмножество Area: зоны, являющиеся странами Зоны и страны образуют древовидный граф

Currency - валюта

```
{
"name": "String"
}
```

Например: RUB, EUR

Employer - работодатель, указывается для всех вакансий, кроме анонимных

```
{
"id": "integer",
"name": "String"
}
```

Schedule - график работы

```
{
"id": "String",
"name": "String"
}
```

Гибкий, полный, и т.д.

Vacancy_type - тип вакансии

```
{
"id": "String",
"name": "String"
}
```

Открытая, закрытая, анонимная

Vacancy - нода вакансии

```
{
"id": "integer", // Название
"name": "String", // Название
```

```
"has_test": "boolean", // Есть ли тестовое
"salary_from": "integer", // Нижняя граница зарплаты
"salary_to": "integer", // Верхняя граница зарплаты
"published_at": "String(DateTime)", // Время публикации вакансии
"created_at": "String(DateTime)", // Время создания вакансии
"requirement": "String", // Требования
"responsibility": "String" // Ответственность
}
```

Список связей (дуг/рёбер)

Метка	Из	В
LOCATED_IN	Vacancy	Area/Country
SALARY_IN	Vacancy	Currency
HAS_EMPLOYER	Vacancy	Employer
HAS_SCHEDULE	Vacancy	Schedule
HAS_TYPE	Vacancy	Vacancy_type
SUBAREA_OF	Area	Area/Country

Графическое представление, здесь для примера представлены две вакансии – в Москве (Аналитик) и СПб (Финансист). У вакансии из СПб не указан работодатель и график работы.

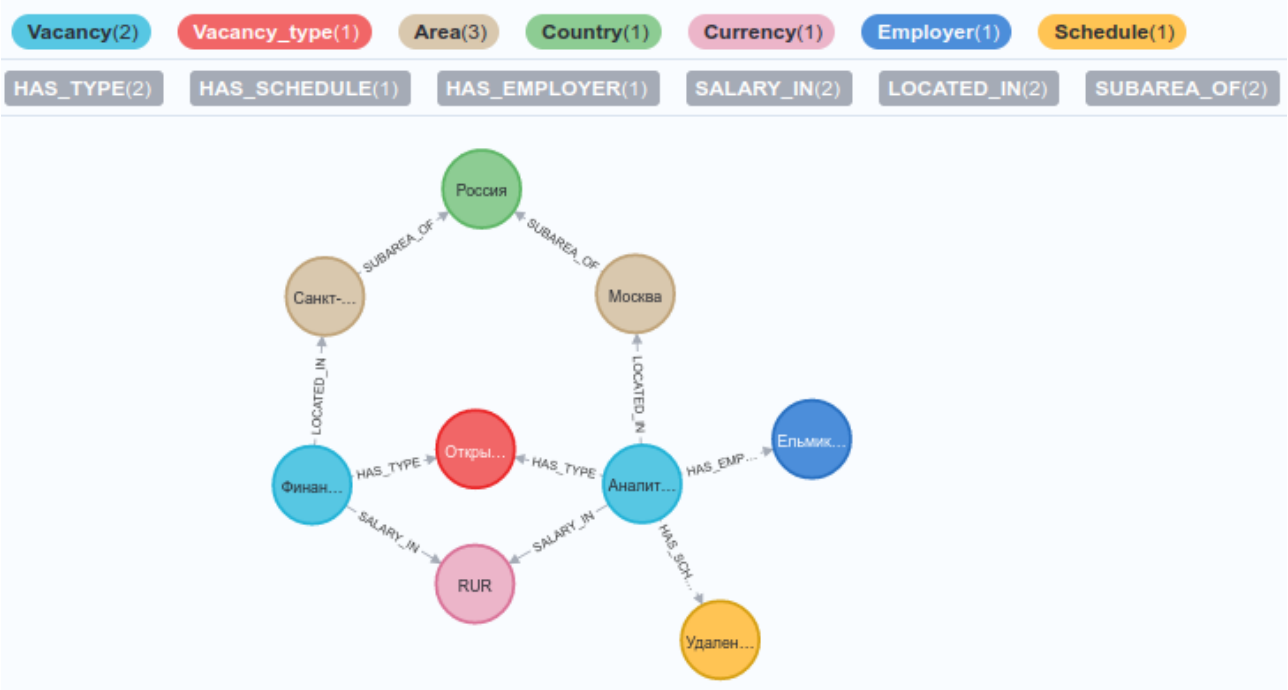

3.2. Оценка удельного объема информации, хранимой в модели

Размеры различных типов данных представлены в документации. Размеры строки приняты за *S* и оценены по верхней границе в 255 байт (размер строк фиксированной длины по умолчанию во многих БД). У всех объектов есть внутренний *ID* размером 8 байт, который имеет смысл учитывать в "чистом" объеме для характеристики ребер. Имеется 7 + 6 различных меток. Положим 1 байт на задание метки объекта.

- Связи

Связи (рёбра) характеризуются *ID* и двумя вершинами, а так же меткой. 3*8 + 1 = 25 байт

- Area/Country

8 + 4 + *S* + 1 = 368 байт

- Currency

Валюта всегда занимает три символа

8 + 3 + 1 = 12 байт

- Employer

8 + 4 + *S* + 1 = 368 байт

- Schedule

8 + 2**S* + 1 = 519 байт

- Vacancy_type

8 + 2**S* + 1 = 519 байт

- Vacancy

8 + 4 + *S* + 1 + 4 + 4 + 4**S* = 1296 байт

Т.е. для БД представленной на рис. в п. "Графическое представление" выше чистый объем составит: 3 * Area + Currency + Employer + Schedule + Vacancy_type + 2 * Vacancy + 10 * Edge = 5364 Байт

Рост объёма от числа вакансий

В худшем случае *N* = #Area = #Currency = #Employer = #Schedule = #Vacancy_type

#Area = #edges = 2*N*

На практике с ростом значений N, количество этих объектов будет стремиться к константе

Объем информации в худшем случае:

$V = N *$ Area $+ N *$ Currency $+ N *$ Employer $+ N *$ Schedule $+ N *$ Vacancy_type $+ N *$ Vacancy $+ 2N *$ Edge

Для $N = 2$ оценка $V = 5600$

Избыточность модели

Чистый объем, посчитан в пред. пункте: 5364 байт = 5.24 kB Практический, получен: 1MB.

Избыточности в модели нет.

Направление роста модели при увеличении количества объектов каждой сущности.

Количество всех объектов зависит от числа вакансий, т.е. объект работодателя появляется в базе только если появляется вакансия с новым работодателем.

- Area, Country - Количество объектов этого типа не превосходит число вакансий и растет в зависимости от числа вакансий не быстрее чем линейно. Так же общее количество регионов ограничено (~7000). При малом количестве данных рост можно оценить как линейный, а при больших - как константный.
- Currency - Количество Валют не превосходит 10, потребление памяти можно оценить как константу.
- Employer - При увеличении количество вакансий растет линейно с большим коэффициентом, т.к. у работодателя может быть несколько вакансий. Рост можно оценить как $O(n*(m*2))$, где n - число работодателей, m - число вакансий, коэффициент излишен, но он показывает затраты на объекты рёбер от вакансий к работодателям.
- Schedule - Количество разновидностей графиков работы константно.
- Vacancy_type - Количество разновидностей типов вакансий константно.
- Vacancy - При росте числа вакансий.

3.3. Запросы к модели, с помощью которых реализуются сценарии использования

Создание вакансии:

```
CREATE (a:Vacancy)
SET a.id = '48621910'
SET a.name = 'Финансовый аналитик'
SET a.has_test = False
SET a.published_at = '2021-11-04T14:52:20+0300'
SET a.created_at = '2021-11-04T14:52:20+0300'
SET a.requirement = 'Высшее профессиональное образование (финансы, экономика, математика). Уверенный пользователь ПК (MSOffice), отличное владение пакетом Excel. Уверенный/продвинутый пользователь 1С, БИТ.Финанс...'
SET a.responsibility = 'Формирование управленческой отчетности, сбор и аналитика данных. Настраивание процесса бюджетирования, бюджетного контроля и управления. Построение управленческой отчетности для пользователей внутри...'
```

Связь вакансии с регионом:

```
MATCH (a:Vacancy {id:'48621910'}),
(b:Area {id:'1')
MERGE (a)-[r:LOCATED_IN]->(b)
```

Получить все вакансии в Москве с зарплатой от 50 тыс.

```
MATCH (v:Vacancy)-[e:LOCATED_IN]->(r:Area{name:'Москва'})
WHERE (v.salary_from>=50000)
RETURN v
```

Оценка числа операций для юзкейсов и CRUD

Благодаря богатому функционалу языка запросов Cypher, юзкейсы реализовываются в один запрос вне зависимости от числа объектов. Создание вакансии в худшем случае потребует создание ещё 6-ти сущностей (см. оценку роста модели), т.е. потребуется от 1 до 7 запросов в зависимости от ситуации и способа написания запроса (можно создавать несколько объектов в одном запросе, но получится громоздко и не обязательно быстрее). Для удаления вакансии потребуется два запроса - для удаления всех связей, а затем самой ноды.

Изменение параметров сущностей происходит за один запрос.

3.4. Аналог модели данных для SQL СУБД

Описанную модель данных можно представить в виде реляционной модели с помощью таблиц.

- Area/Country - множество всех зон расположения вакансии (страна/город) с идентификатором, названием и индексом зоны, подмножеством которой он является.
- Vacancy_type - множество типов вакансий (открытая/закрытая/анонимная) с идентификатором и названием.
- Schedule - множество видов графика работы (гибкий/полный и т.д.) с идентификатором и названием.
- Employer - множество всех работодателей с идентификатором и названием.
- Vacancy - множество всех вакансий с идентификатором, названием, зоной расположения, типом вакансии, графиком работы, работодателем, валютой, верхней и нижней границей заработной платы, тестовым заданием, временем создания и публикации вакансии, требованиями и ответственностью.

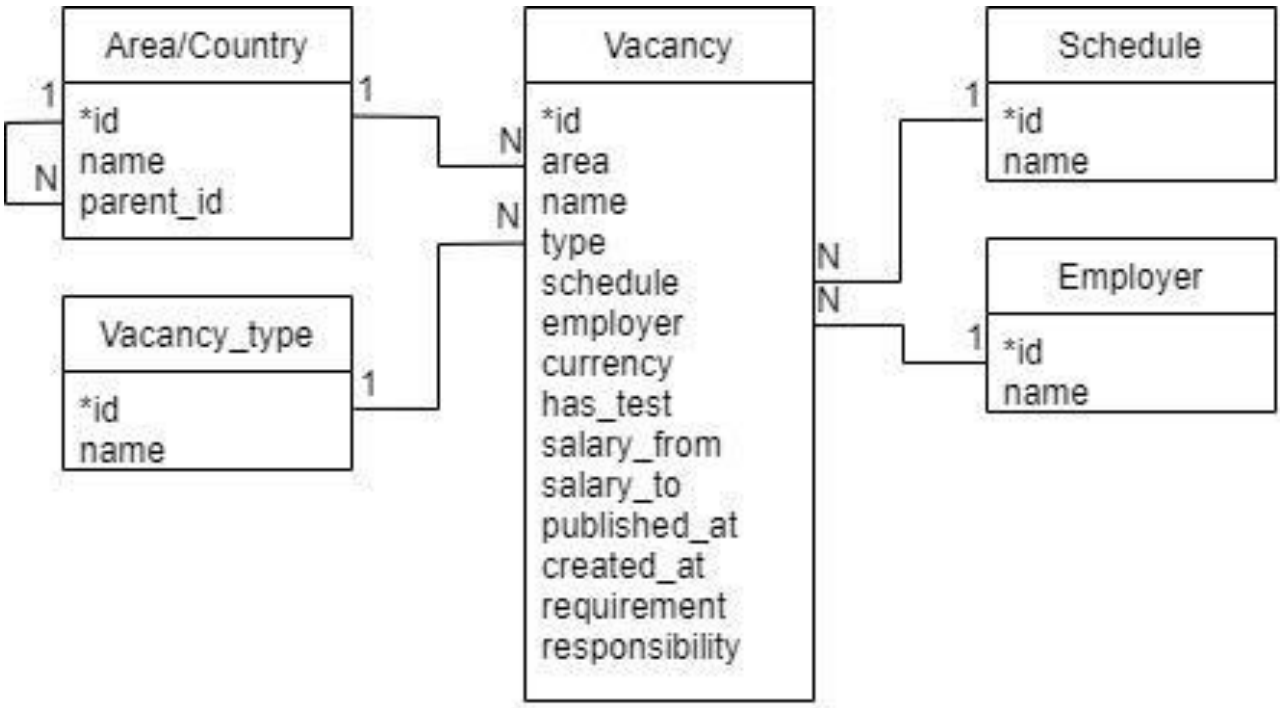

Запросы к модели

Создание вакансии:

```
INSERT INTO Vacancy
```

```
VALUES (area, name, type, schedule, employer, currency, has_test,
salary_from, salary_to, published_at, created_at, requirement, responsibility);
```

Все вакансии в Москве с зарплатой от 50 тыс.

```
SELECT * FROM Vacancy
WHERE Vacancy.salary_from >= 50000 AND Vacancy.area = 'Москва';
```

Оценка числа операций для юзкейсов и CRUD

Удаление связано со сложностями выбора стратегии (setnull/cascade).

Добавление сущностей происходит за один запрос, но при добавлении вакансии может так же понадобится добавить до 6-ти других сущностей, соответственно ищет за 6 запросов.

Изменение информации происходит в один запрос.

Наибольшие трудности связаны с выборкой информации по многим фильтрам, т.к. для фильтрации по параметрам связных сущностей потребуется JOIN большого числа таблиц, соответственно породит большие запросы, которые трудно оптимизировать.

Оценка удельного объема информации, хранимой в модели

Положим размер *ID* 8 байт, размер строки *S* = 255 байт

- Area/Country

8 + *S* + 8 = 271

- Employer

8 + *S* = 263

- Schedule

2**S* = 510

- Vacancy_type

2**S* = 510

- Vacancy

8 + 8 + *S* + 8 + 8 + 8 + 3 + 1 + 4 + 4 + 4**S* = 1327

Т.е. для БД представленной на рис. в п. "Графическое представление" выше чистый объем составит: 3 * Area + Employer + Schedule + Vacancy_type + 2 * Vacancy = 4750

Рост объёма от числа вакансий

В худшем случае N = #Area = #Employer = #Schedule = #Vacancy_type

#Area = 2N

Объем информации в худшем случае: V = 2N * Area + N * Employer + N * Schedule + N * Vacancy_type + N * Vacancy

Для N = 2 оценка V = 6304

Избыточность модели

Чистый объем, посчитан в пред. пункте: 6304 байт = 6.3 kB

Практический, получен: 7MB

Избыточности в реляционной модели нет

Сравнение моделей

По памяти

В графовой модели чистый объем для заданных данных составил 5364 байт.

В реляционной для такой же конфигурации 4750. Экономия достигается в основном из-за отсутствия необходимости хранить рёбра, т.к. связь происходит через ключи.

По запросам

По запросам для создания информации графовая БД имеет теоретическое преимущество, т.к. может создавать цепочки сущностей за раз, что позволит делать меньше запросов при одновременном добавлении нескольких вакансий и вспомогательных объектов к ним.

По запросам для изменения информации большого различия нет

Удаление информации доставляет сложности в обоих случаях, т.к. надо решить, что делать со связями/ссылками на удаляемый объект, однако в графовой БД нет фиксированной схемы, по этому процесс удаления проще.

Больше всего преимущества графовая БД имеет в решении юзкейсов приложения, т.к. позволяет делать запросы со сложными связями быстрее. Например запрос всех вакансий в СПб с заданной зарплатой, от заданного работодателя с удаленным форматом: В графовой модели потребуется сделать MATCH по связям с тремя вершинами (работодатель, график, регион) и фильтрации по параметрам. В случае с реляционной моделью это потребует

написания JOIN запроса по трем таблицам и фильтрации по результату, что сложнее.

Можно сделать вывод, что для задач аналитики графовая БД имеет преимущество, не смотря на проигрыш по дисковому пространству.

3.5. Модель данных для MongoDB

Графическое представление:

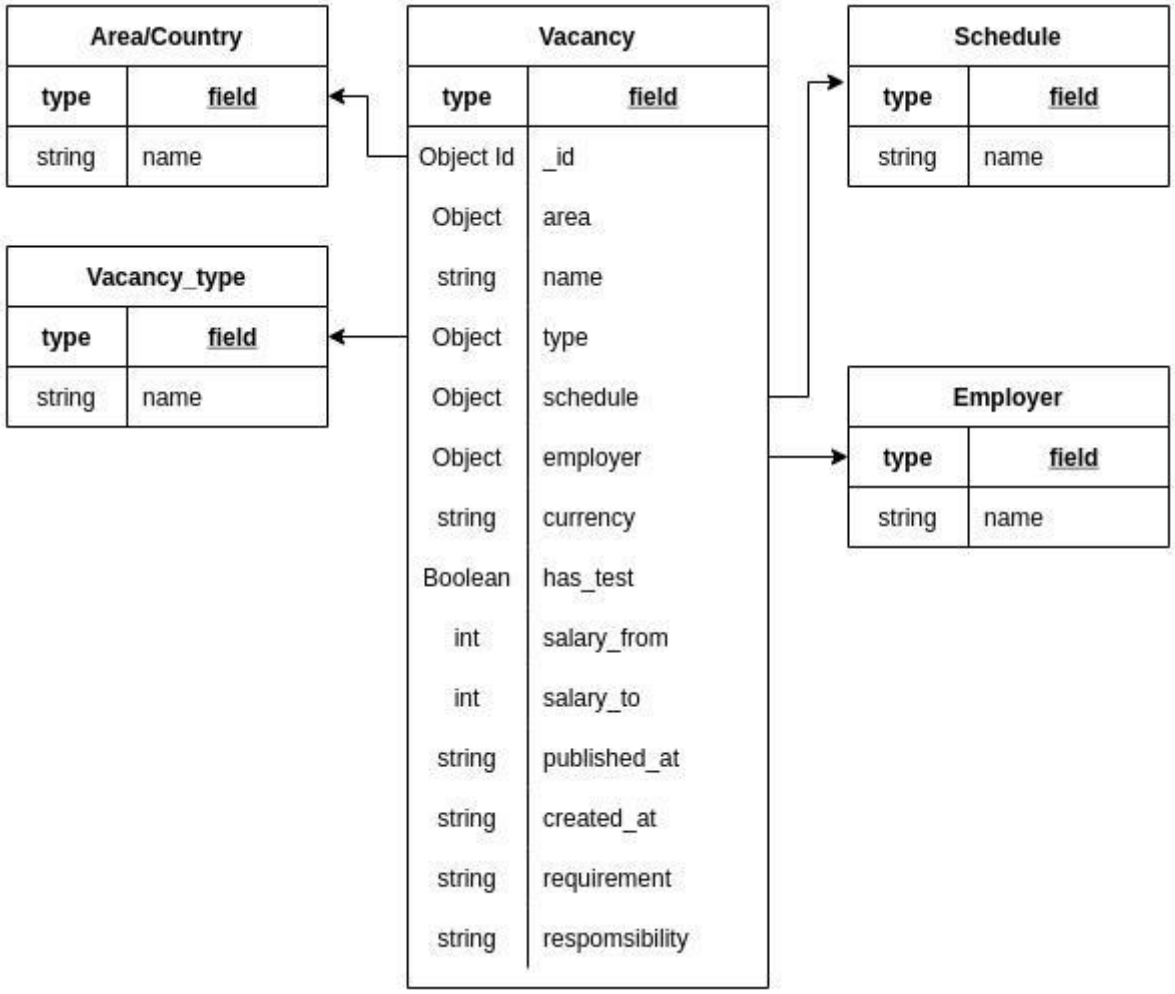

Оценка объема

- Объем для одного объекта Area/Country
  name - string - 255 символов, 255 байт V(Area/Country) = 255 байта
- Объем для одного объекта Vacancy_type
  name - string - 255 символов, 255 байт V(Vacancy_type) = 255 байта
- Объем для одного объекта Schedule
  name - string - 255 символов, 255 байт V(Schedule) = 255 байта
- Объем для одного объекта Employer

name - string - 255 символов, 255 байт V(Employer) = 255 байта

- Объем для одного объекта Vacancy

  _id - ObjectId - 12 байт

  name - string - 255 символов, 255 байт

  currency - string - 5 символов, 5 байт

  has_test - boolean - 2 байт

  salary_from - int - 4 байт

  salary_to - int - 4 байт

  published_at - string - 255 символов, 255 байт

  created_at - string - 255 символов, 255 байт

  requirement - string - 255 символов, 255 байт

  responsibility - string - 255 символов, 255 байт

  Area/Country - Object - V(Area/Country) = 255 байт

  Vacancy_type - Object - V(Vacancy_type) = 255 байт

  Schedule - Object - V(Schedule) = 255 байт

  Employer - Object - V(Employer) = 255 байт

  V(Vacancy) = 2322 байт Для N = 2 оценка V = 6304

Рост объёма от числа вакансий

V(объём данных в коллекции Vacancy) = N * V(объект коллекции Vacancy) = 2 * 2322 байт = 4644 байт, при N = 2 Данные растут линейно.

Избыточность модели

Избыточность модели низка, повторяющиеся фрагменты несущественны по объему.

Запросы к модели

Создание вакансии:

```
db.vacancies.insertOne(
{
"name":"Финансовый аналитик",
"has_test":false,
"published_at":"2021-11-04T14:52:20+0300",
"created_at":"2021-11-04T14:52:20+0300",
```

```
"requirement":"Высшее профессиональное образование (финансы, экономика, математика). Уверенный пользователь ПК (MSOffice), отличное владение пакетом Excel. Уверенный/продвинутый пользователь 1С, БИТ.Финанс...",
"responsibility":"Формирование управленческой отчетности, сбор и аналитика данных. Настраивание процесса бюджетирования, бюджетного контроля и управления. Построение управленческой отчетности для пользователей внутри...",
"area":{
"name":"Москва"
},
"type":{
"name":"Открытая"
},
"schedule":{
"name":"Full time job"
},
"employer":{
"name":"Яндекс"
}
)
```

Все вакансии в Москве с зарплатой от 50 тыс.

```
db.vacancies.find( { area: "Москва" }, : salary_from: { $gt: 50000 } )
```

Оценка числа операций для юзкейсов и CRUD

Удаление не имеет сложностей, при удалении документа коллекции (Vacancy) также удаляются все вложенные документы.

Добавление и изменение также происходит за один запрос. Существенных трудностей тривиальные операции CRUD не имеют.

Сравнение моделей

По памяти

MongoDB занимает схожий объем данных по сравнению с SQL (MongoDB 4644 байт vs SQL DB 4750 байт) и существенно меньше чем графовая БД Neo4j (5600 байт). Избыточность модели низка, повторяющиеся фрагменты несущественны по объему.

По запросам

В случае документо-ориентированной БД рассматриваемый выше запрос поиска (Зарплата в Москве > 50 000) должен выполняться быстрее по сравнению с SQL БД (отсутствует ресурсно-затратная операция JOIN, информация о локации хранится во вложенном документе) и с Neo4j (операция MATCH).

4. Разработанное приложение

4.1. Краткое описание

4.1.1. Архитектура

Приложение состоит из трёх сервисов, взаимодействующих между собой

- Neo4j - база данных
- Rest - бэкэнд. Содержит бизнес-логику приложения. Общается с базой данных посредством запросов на языке запросов Cypher. Предоставляет REST-api для фронтенда. Rest-api генерируется на основе документации Openapi 3, при помощи connexion
- ui - фронтэнд. Обращается к REST-api и реализует взаимодействие с пользователем

4.1.2. Docker

Каждый сервис контейнирезирован. Он исполняется в изолированной среде со всеми необходимыми ему зависимостями. Файлы конфигураций пробрасываются в контейнер при сборке

Для управления несколькими контейнерами используется docker-compose

4.2. Схема экранов приложения

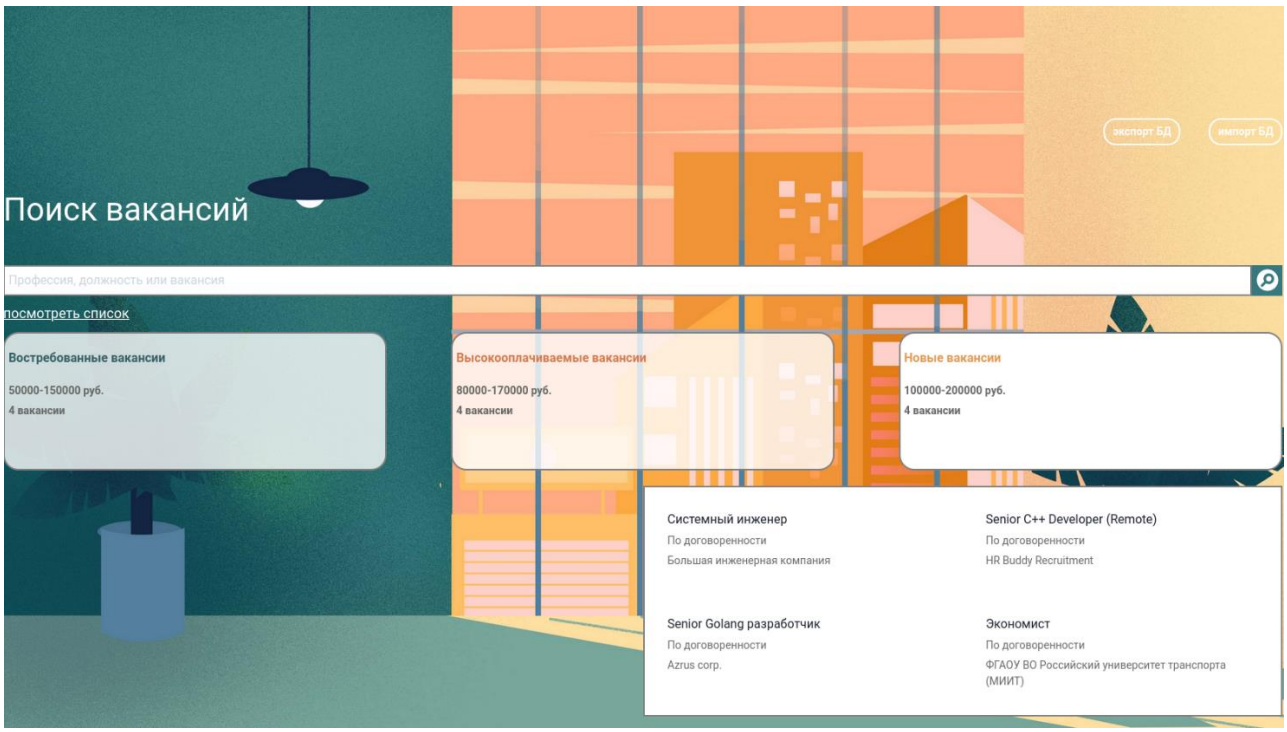

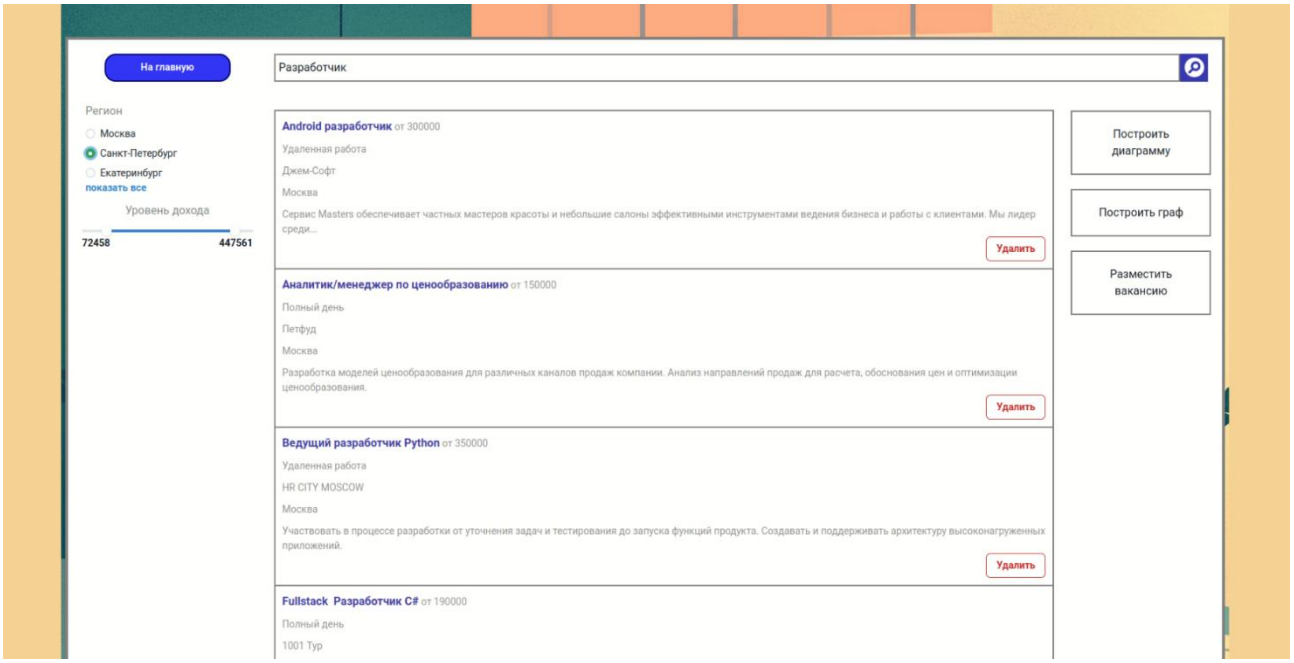
На главную
Разработчик
Регион
Москва
Санкт-Петербург
Екатеринбург
показать все
Уровень дохода
72458
447561
Android разработчик от 300000
Удаленная работа
Джем-Софт
Москва
Сервис Masters обеспечивает частных мастеров красоты и небольшие салоны эффективными инструментами ведения бизнеса и работы с клиентами. Мы лидер среди...
Удалить
Аналитик/менеджер по ценообразованию от 150000
Полный день
Петфуд
Москва
Разработка моделей ценообразования для различных каналов продаж компании. Анализ направлений продаж для расчета, обоснования цен и оптимизации ценообразования.
Удалить
Ведущий разработчик Python от 350000
Удаленная работа
HR CITY MOSCOW
Москва
Участвовать в процессе разработки от уточнения задач и тестирования до запуска функций продукта. Создавать и поддерживать архитектуру высоконагруженных приложений.
Удалить
Fullstack Разработчик C# от 190000
Полный день
1001 Тур
Построить диаграмму
Построить граф
Разместить вакансию

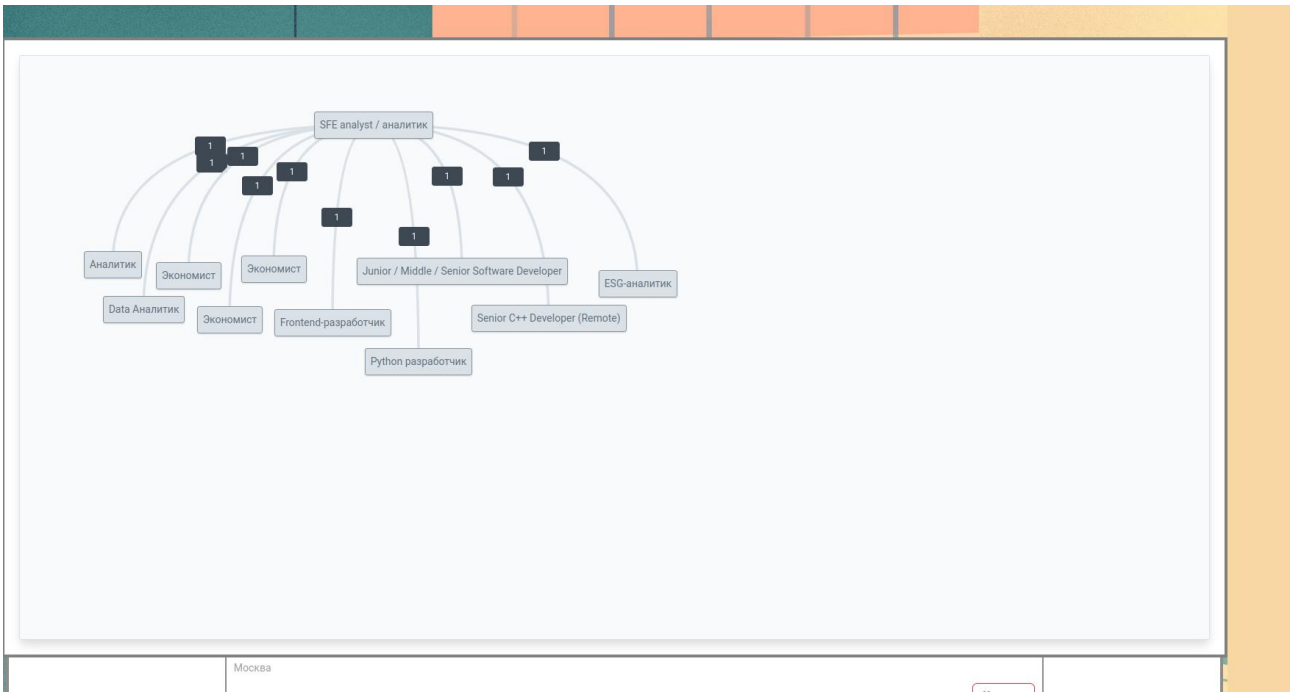
SFE analyst / аналитик
Аналитик
Экономист
Экономист
Junior / Middle / Senior Software Developer
ESG-аналитик
Data Аналитик
Экономист
Frontend-разработчик
Senior C++ Developer (Remote)
Python разработчик
Москва

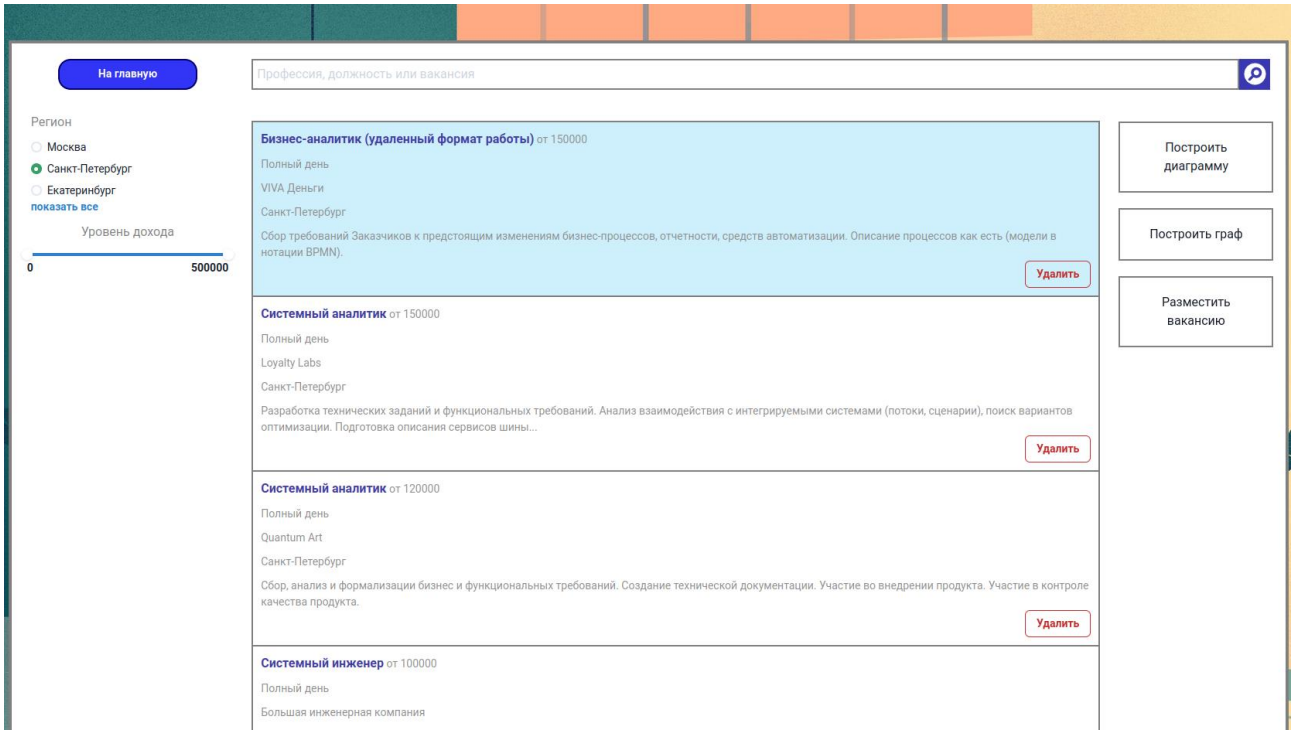

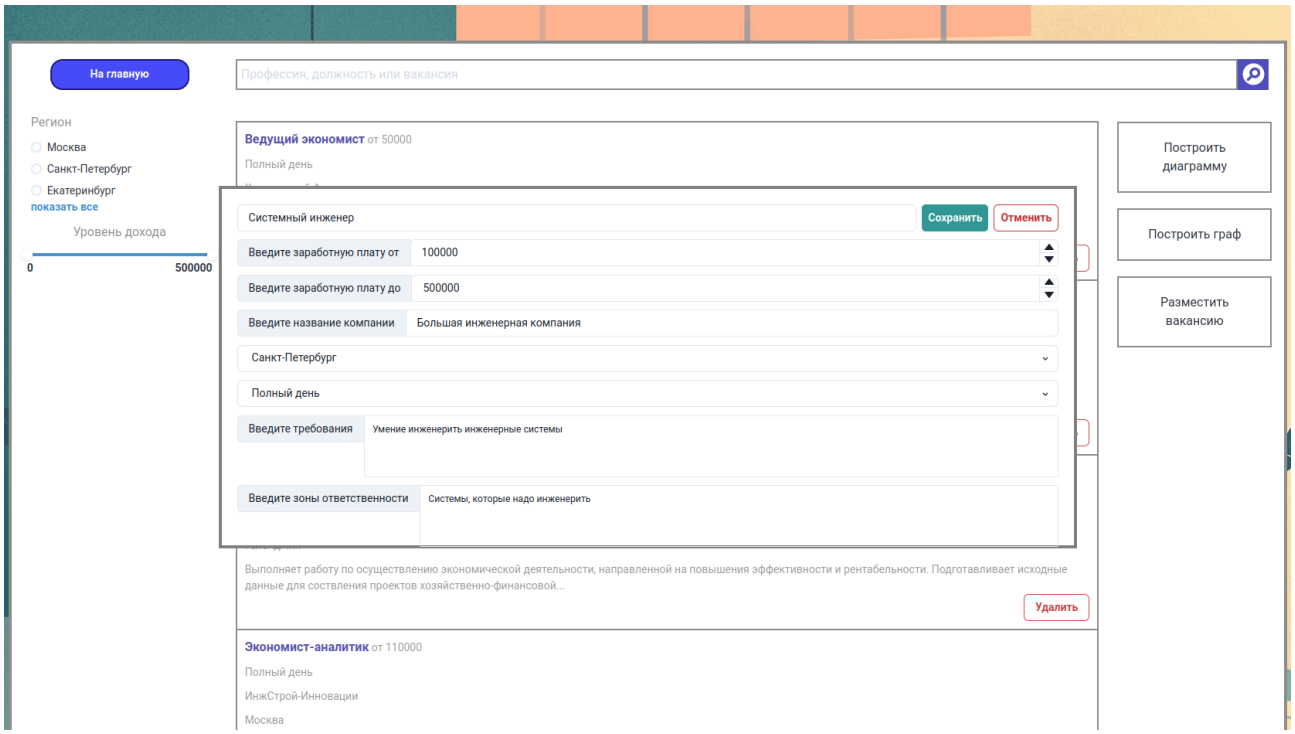

4.3. Использованные технологии

БД: Neo4j

Back-end: Flask, Swagger (OpenAPIv3), connexion

Front-end: React

4.4. Ссылки на приложение

https://github.com/moevm/nosql2h21-jobs

ЗАКЛЮЧЕНИЕ

В процессе работы был разработан веб-инструмент для БД вакансий, который позволяет пользователю удобно и быстро добавлять и удалять вакансии, просматривать БД на странице табличного представления и строить граф по степени сходства вакансий. На стартовой странице есть аналитика самых востребованных, оплачиваемых и новых вакансий.